

Capítulo 1

Introdução à Otimização Matemática

A otimização matemática é definida como o processo sistemático de encontrar as entradas ideais para um problema específico. Como cientistas de dados e engenheiros, utilizamos essas técnicas para modelar e resolver cenários do mundo real, traduzindo desafios de negócios em formulações matemáticas rigorosas.

As aplicações práticas da otimização são vastas e permeiam diversos setores da economia:

- **Agricultura de Precisão:** Técnicas de otimização são empregadas para maximizar o rendimento das safras, determinando a melhor quantidade e qualidade da colheita com base em variáveis climáticas e nas condições do solo.
- **Logística e Cadeia de Suprimentos:** Emprega-se a otimização para definir rotas ideais de distribuição de frotas. Isso envolve a análise complexa de distâncias e tráfego interurbano com o objetivo final de melhorar os tempos de entrega e reduzir os custos operacionais.

1.1 A Função Objetivo

No cerne de qualquer problema de otimização está a formulação da função objetivo. Ela é a representação matemática que descreve a relação direta entre as variáveis de entrada de um sistema e o resultado quantitativo que desejamos alcançar.

Para ilustrar este conceito de forma aplicada, considere o cenário tático de uma fábrica de móveis cujo objetivo primordial é maximizar o seu lucro,

o qual denotaremos pela variável P . Sabemos que o lucro está atrelado à quantidade de móveis produzidos, representada pela variável de decisão q . Após análises financeiras, a equipe de dados determinou que a função objetivo para este problema é dada pela equação quadrática:

$$P = 40q - 0.5q^2. \quad (1.1)$$

O desafio central da otimização neste cenário consiste em responder a uma pergunta direta: qual valor de q maximiza P ? Em termos geométricos e analíticos, o valor máximo atingido por esta função em uma curva representa o nosso valor ótimo. O formato parabólico da função — indicando que lucros caem se a produção for excessiva — reflete restrições do mundo real, como a insuficiência de pessoal ou limitações de capacidade do equipamento da fábrica.

1.2 O Método da Busca Exaustiva

Antes de avançarmos para técnicas analíticas envolvendo cálculo diferencial (como o uso de derivadas), é imperativo compreendermos as metodologias computacionais básicas. Um dos métodos primordiais para a resolução computacional é a busca exaustiva.

Também conhecido na literatura da computação como o método de "força bruta", a busca exaustiva é um algoritmo conceitualmente simples que opera da seguinte maneira:

1. Calcula-se o resultado da função objetivo (o lucro) para um intervalo inteiro de quantidades possíveis.
2. Examina-se o espaço de resultados e seleciona-se a quantidade que produz o maior lucro.

1.2.1 Avaliação do Método: Vantagens e Desvantagens

Como qualquer técnica algorítmica, o método de busca exaustiva deve ser avaliado criticamente quanto à sua viabilidade:

- **Vantagens:** Este método goza de uma implementação extremamente simples. Além disso, não há a necessidade de aquisição de hardwares ou softwares caros e ele opera sob suposições matemáticas mínimas sobre o formato ou continuidade da função.

- **Desvantagens:** A limitação fundamental do método de força bruta é a maldição da dimensionalidade; ele não escala computacionalmente para resolver casos complexos ou problemas que envolvam múltiplas variáveis contínuas.

1.2.2 Implementação e Exemplo Prático em Python

Para materializar o método da busca exaustiva, podemos utilizar a linguagem Python, uma ferramenta padrão na Ciência de Dados, aproveitando as capacidades de processamento numérico da biblioteca NumPy.

Retornando ao nosso exemplo da manufatura de móveis, simularemos a produção para um intervalo de 0 a 79 unidades. O bloco de código a seguir detalha esta implementação:

```
1 import numpy as np
2
3 # Define o array de variaveis de entrada (quantidades de
4   0 a 79)
5
6 # Define a funcao objetivo de lucro
7 def profit(q):
8     return 40 * q - 0.5 * q**2
9
10 # Computa exaustivamente o lucro para o intervalo
11   definido
12
13 profits = profit(qs)
14
15 # Identifica o valor de lucro maximo no array gerado
16
17 max_profit = profits.max()
18
19 # Encontra o indice no array que corresponde ao valor
20   otimo
21
22 max_ind = np.argmax(profits)
23
24 # Mapeia o indice de volta para a variavel de decisao
25   ideal
26
27 q_opt = qs[max_ind]
28
29 # Exibe o resultado final
30
31 print(f"The optimum is {q_opt} pieces of furniture, which
32       makes ${max_profit} profit.")
```

Listing 1.1: Busca exaustiva para maximização de lucro utilizando NumPy.

Ao submeter a nossa função à força bruta computacional descrita acima, o algoritmo varre o vetor de lucros e infere deterministicamente a nossa resposta. O output final do modelo nos informará que o ponto ótimo de operação é fabricar exatas 40 peças de mobiliário, o que gerará para a empresa um lucro máximo de \$800.